Introducción a la Genómica UNAL nov 2017

Alejandro Cáceres ISGlobal, Barcelona

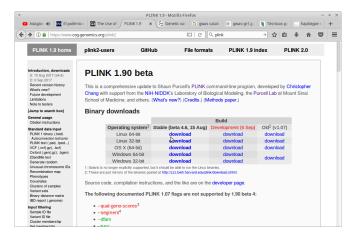
November 8, 2017

datos de SNPs

Cada programa tiene un formato diferente y es importante saber cambiar de formato

- ► PLINK: Es un programa compilado, corre por la linea de comandos y es muy rápido. Es particularmente útil para manejar las bases de datos en si, exlcuir sujetos, seleccionar SNPs. No tiene la versatilidad de R para explorar gráficos, crear nuevas funciones o hacer gráficos, pero es muy utilizado y con experiencia en computación fácil de hacer pipelines.
- snpStats (bioconductor): Tiene varias funciones para ver la estructura de los datos (linakage-disequilibium, pca, Fst), y hace análisis de asociación en base de datos grandes, pero no prueba diferentes modelo de herencia. Usa un fromato especial (raw data).
- snpAssoc (r-cran): versatil para probar diferentes modelos de herencia, pero las funciones no están optimizadas para menejar matrices muy grandes.
- ► tabix : un programa para gestionar datos en formato VCF usado por los 1000 genomas

Es un programa por linea de comandos desarrollado por Chrostopher Chang.



Tiene una documentación muy completa

PLINK tiene dos formatos

- .bed, .bim, .fam: es el mas usado y separa la información en tres: archivos genotipos (.bed), anotacion de SNPs (.bim), fenotipos (.fam)
- .ped, .map: .ped son los .fam en las primeras columnas y .map es una versión con menos info que .bim

Para cambiar los cambiar el formatos de misDatos.ped y misDatos.map a misDatos.bed, misDatos.bim y misDatos.fam

plink --file misDatos --make-bed --out misDatos

Datos de SNPs

Después del preprocesamiento de los datos, los datos que se obtienen es de un genotipo por individuo. Si tenemos 1 millon de SNPs y 1000 individuos, esto es tipicamente una matriz de $10^3 \times 10^6$. Hay diferentes formas de organizar estos datos

```
rs33 rs36 rs43
NA090 A/C G/G T/A ...
NA091 A/A G/G T/A ...
NA092 A/A G/C T/A ...
NA093 A/C C/C A/A ...
```

. . .

Datos de SNPs

```
rs33 rs36 rs43
NA090 A/C G/G T/A ...
NA091 A/A G/G T/A ...
NA092 A/A G/C T/A ...
NA093 A/C C/C A/A ...
```

Una forma eficiante es llamar 0:homocigoto, 1:heterocigoto y 2:heterocigoto variante.

para SNP=rs33 el alelo mas frecuente es A y el menos frecuente es C.

Entonces: A/A=0, A/C=1, CC=2

para SNP=rs36 el alelo mas frecuente es G y el menos frecuente es C.

Entonces: G/G=0, G/C=1, CC=2



Datos típicos de SNPs (PLINK) formato bed

Datos de los genotipos (datos.bed)

```
      rs33
      rs36
      rs43

      NA090
      1
      0
      1
      ...

      NA091
      0
      0
      1
      ...

      NA092
      0
      1
      1
      ...

      NA093
      1
      2
      2
      ...
```

. . .

Datos típicos de SNPs (PLINK) formato bed

Datos con la anotacion de SNPs (datos.bim)

```
      chr snp
      mor
      pos
      allele1
      allele2

      1
      rs33
      0
      1034
      A
      C

      1
      rs36
      0
      2000
      G
      C

      1
      rs43
      0
      10056
      T
      A
```

. . .

Datos tipicos de SNPs (PLINK) formato bed

▶ Datos con los fenotipos (datos.fam)

ID	FI	AMID	sex	asthma	BMI-z
NAO	90	1	1	1	1.2
NAO	91	1	1	0	1.5
NAO	92	2	0	0	0.9
NAO	93	2	0	1	1

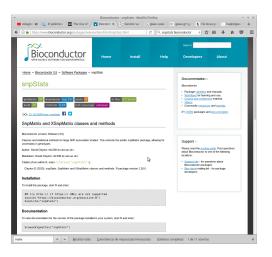
en https://www.cog-genomics.org/plink/1.9/resources hay datos de prueba para aprender a usar PLINK Si PLINK esta instalado

- bajar 1kg_phase1_chr22.tar.gz
- descomprimir
- ejecutar

plink --bfile 1kg_phase1_chr22 --make-bed --chr 22 --out mydata --to-mb 20

Esto selecciona unos datos del cromosoma 22 hasta 20 Mb y los guarda en mydata.bed, mydata.fam y mydata.bim

Es un programa en R (Bioconductor)



tiene la ventaja de que esta en ambiente R y se pueden usar otros paquetes de Bioconductor/R

se instalala como desde R por medio de los comandos

```
source("https://bioconductor.org/biocLite.R")
biocLite("snpStats")
```

Todos los paquetes de Bioconductor tienen manuales de usuarios (vineta)

la librería se carga con

```
library("snpStats")

## Loading required package: survival

## Loading required package: Matrix
```

cargemos los datos

```
snp<-read.plink("datos/mydata")

## Warning: non-unique value when setting 'row.names': '.'
## Error in 'row.names<-.data.frame'('*tmp*', value = value):
duplicate 'row.names' are not allowed</pre>
```

Un error típico de cuando algunos SNPs no están anotados

Veamos cuales son los SNPs que estan anotados

```
bim<-read.table("datos/mydata.bim",as.is=TRUE)

rs<-bim[,2]
tb<-table(rs)
dup<-tb[tb>1]
selrs<-rs[!rs%in%names(dup)]
head(rs)

## [1] "rs149201999" "rs146752890" "rs139377059" "rs188945759" "rs65183
## [6] "rs62224609"</pre>
```

Lamos los SNPs anotados usando la opción select.snps

```
snp<-read.plink("datos/mydata", select.snps = selrs)
names(snp)
## [1] "genotypes" "fam" "map"</pre>
```

```
snp$genotypes

## A SnpMatrix with 1092 rows and 43067 columns
## Row names: HG00096 ... NA20828
## Col names: rs149201999 ... rs145875228
```

```
head(snp$fam)
        pedigree member father mother sex affected
##
             NA HG00096 <NA>
## HG00096
                             <NA> 1
                                        NΑ
## HG00097
             NA HG00097 <NA> <NA> 2
                                        NΑ
## HG00099
            NA HG00099 <NA> <NA> 2
                                        NA
## HG00100
            NA HG00100 <NA> <NA> 2
                                        NΑ
## HG00101 NA HG00101 <NA> 1
                                        NA
## HG00102
            NA HG00102 <NA>
                             <NA>
                                        NA
```

```
head(snp$map)

## chromosome snp.name cM position allele.1 allele.2

## rs149201999 22 rs149201999 NA 16050408 C T

## rs146752890 22 rs146752890 NA 16050612 G © Q C
```

se pueden guardar como binarios de R file.RData

```
save(snp, file="datos/mydata.RData")
```

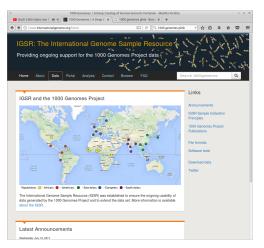
también se pueden guardar datos de snpStats en PLINK con write.plink

Estos son solo genotipos guardados en binario snp.RData

```
load("datos/snp.RData")
```

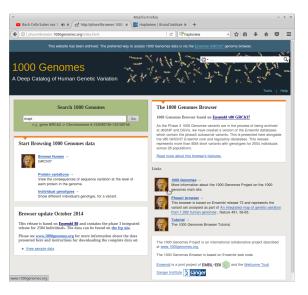
```
## A SnpMatrix with 1500 rows and 439 columns
## Row names: 1 ... 1500
## Col names: 1 ... 439
```

Repositorio de datos de los 1000 genomas donde se pueden descargar los datos de 2504 individuos

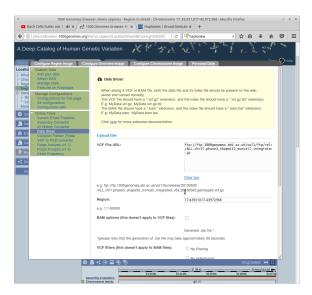


Hay un servidor ftp para descargar datos. Los archivos son enormes, pero se puden leer por regiones con Tabix

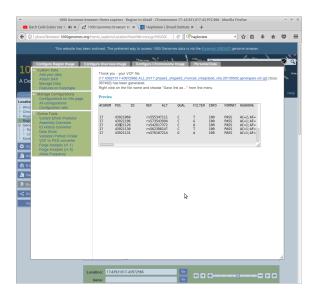
También hay un browser para bajar datos de regiones



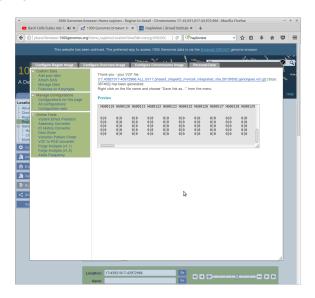
obtengamos datos para MAPT



Formato VCF

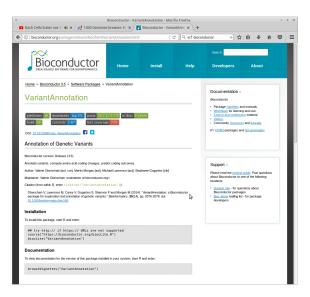


Formato VCF



Bioconductor

Paquete Variant Annotation para leer datos VCF

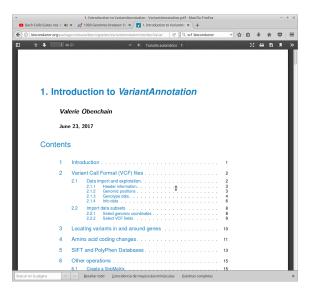


se pueden cargar los binarios snp.RData

```
source("http://bioconductor.org/biocLite.R")
biocLite("VariantAnnotation")
```

Bioconductor

Variant annotation



##

##

MEND

MT.F.N

```
library(VariantAnnotation)
fl<-"datos/17.43921017-43972966.ALL.chr17.phase3_shapeit2_mvncall_integ
vcf <- readVcf(fl, "hg19")</pre>
vcf
## class: CollapsedVCF
## dim: 1863 2504
## rowRanges(vcf):
     GRanges with 5 metadata columns: paramRangeID, REF, ALT, QUAL, FIL
##
## info(vcf):
##
     DataFrame with 27 columns: CIEND, CIPOS, CS, END, IMPRECISE, MC, M
## info(header(vcf)):
##
                    Number Type Description
      CTEND
                           Integer Confidence interval around END for i
##
##
     CIPOS
                           Integer Confidence interval around POS for i
##
      CS
                           String Source call set.
     END
##
                           Integer End coordinate of this variant
##
     IMPRECISE
                           Flag
                                   Imprecise structural variation
                           String Merged calls.
##
     MC
##
      MEINFO
                    4
                           String Mobile element info of the form NAME
```

Integer Mitochondrial end coordinate of inse

```
genos<-geno(vcf)</pre>
names(genos)
## [1] "GT"
dim(genos$GT)
## [1] 1863 2504
genos$GT[1:5,1:5]
              HG00096 HG00097
##
                              HG00099 HG00100 HG00101
## rs555347111 "0|0"
                      "0|0"
                              "0|0"
                                      "010"
                                              "0|0"
                                      "010"
## rs573543994 "0|0"
                      "010"
                              "010"
                                               "010"
                                      "010"
## rs542617372 "0|0"
                      "010"
                              "010"
                                              "0|0"
                       "010"
                              "010"
                                      "010"
                                               "010"
## rs562398147 "0|0"
## rs576107214 "0|0"
                       "0|0"
                              "010"
                                       "010"
                                               "010"
```

Si el archivo es grande readVcf permite leer sólo regiones de interes

Los genotipos en formato 0,1,2 pueden ser encontrados en *genos*\$DS.

Si no se puede entonces se puede calcular asi

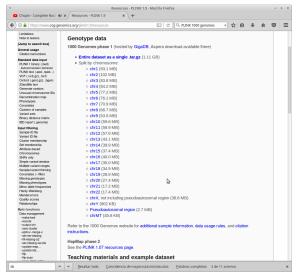
```
snps<-genos$GT
snps[snps=="0|0"]<-0
snps[snps=="1|1"]<-2
snps[snps!=0 & snps !=2]<-1
snps[1:5,1:5]
##
                 HG00096 HG00097 HG00099 HG00100 HG00101
                                     '' O ''
                                               '' () ''
## rs555347111 "0"
                           "O"
                                                        "0"
                           "0"
                                     "0"
                                               '' O ''
                                                        " ∩ "
## rs573543994 "0"
                                     '' O ''
## rs542617372 "0"
                           '' ∩ ''
                                               '' O ''
                                                        " ∩ "
                                     "O"
                                               '' () ''
                                                        "O"
## rs562398147 "0"
                           "O"
## rs576107214 "0"
                           11 () 11
                                     " ∩ "
                                               11 () 11
                                                        " ∩ "
save(snps, file="snpsMAPT.RData")
```

VCF in snpStats

snpStats usa formato 1,2,3 para genotipos y el 0 para missing

```
library(snpStats)
snpsnew<-t(snps)</pre>
snpsnew[snps=="0"] <- 1</pre>
snpsnew[snps=="1"] <- 2</pre>
snpsnew[snps=="2"] <- 3</pre>
snpsSNPstats <- new("SnpMatrix", snpsnew)</pre>
## coercing object of mode character to SnpMatrix
print(as(snpsSNPstats[1:5,1:5], 'character'))
         rs555347111 rs573543994 rs542617372 rs562398147 rs576107214
##
## HGO0096 "A/A" "A/A" "A/A" "A/A" "A/A"
## HG00097 "A/A" "A/A" "A/A" "A/A" "A/A"
## HGO0099 "A/A" "A/A" "A/A" "A/A" "A/A"
## HG00100 "A/A" "A/A" "A/A" "A/A" "A/A"
## HGOO101 "A/A" "A/A" "A/A" "A/A" "A/A"
save(snpsSNPstats, file="snpsSNPstats.RData")
```

Los datos de los 1000 genomas (y HapMap) también están en formato PLINK por chromosomas



PLINK a VCF

- los comandos PLINK puden usar formato VCF
- también se puede convertir .bed .bim .fam a formato a VCF y vise-versa

```
$ plink --bfile [filename prefix] --recode vcf --out [VCF prefix]
$ plink --vcf [VCF filename] --out [.bed/.bim/.fam prefix]
```

Ejercicio

- Descargar datos de los 1000 Genomas en formato PLINK
- ► leerlos en snpStats
- si PLINK está instalado convertirlos en VCF
- ▶ leerlos en R